

# Clasificación de Imágenes con Deep Learning

Primera entrega

Vanessa Tocasuche Ochoa

Fundamentos de Deep Learning

Universidad de Antioquia

2025

## 1. Contexto de aplicación.

A continuación, se presenta un ejemplo de aplicación de técnicas de **Deep Learning** orientado a la **clasificación de imágenes**, específicamente en la identificación de dos tipos de frutas: manzanas y tomates. Este caso práctico evidencia la relevancia de este tipo de soluciones en contextos industriales y agrícolas, donde la clasificación visual precisa de productos es una tarea esencial para optimizar procesos, reducir errores humanos y mejorar la eficiencia operativa.

Por ello, a partir de un data set obtenido en Kaggle, se desarrolla una solución orientada a este tipo de problemas, donde la optimización del modelo resulta fundamental para minimizar los falsos negativos en la clase de mayor costo —en este caso, las manzanas—, contribuyendo así a mejorar la precisión del sistema y la eficiencia operativa del proceso de clasificación.

## 2. Objetivo de Deep Learning

- Predecir si una imagen muestra una manzana o tomate mediante una plantilla de modelo para la extracción de características visuales, dada un conjunto de imágenes de tomates y manzanas clasificadas previamente.
- Procesar un conjunto de datos de imágenes mediante algunos temas de Fundamentos de Deep Learning como lo son Redes Neuronales Convolucionales para la extracción de características, dropout y pooling con la extracción de características más representativas para controlar el sobreajuste en datasets pequeños.

## 3. Dataset

Tipo de datos

Imágenes con extensión .jpeg

Tamaño (número de datos y tamaño en disco)

391 imágenes que ocupan 3,05 MB o 3,203,072 bytes

Distribución de las clases

Manzanas 218

Tomates 173

## 4. Métricas de desempeño

		Valor real		Total
Valor predicción	P	Verdaderos positivos	Falsos positivos	P'
	N	Falsos negativos	Verdaderos negativos	N'
Total		P	N	

Verdaderos positivos (VP)  
Verdaderos negativos (VN)  
Falsos positivos (FP)  
Falsos negativos (FN)

Fuente: Universidad Externado de Colombia

## Métricas para clasificación

### Métricas de mayor valor:

- Accuracy  $(VP + VN) / (VP + VN + FP + FN)$
- Presicion  $VP / (VP + FP)$
- Recall  $VP / (VP + FN)$

### Métricas complementarias

- F1-score  $2 * (Precision * Recall) / (Precision + Recall)$
- Matrix de confusión Tabla de imagen anterior

- **AUC-ROC**                      Capacidad del modelo para distinguir entre clases  
(Área bajo la curva  
ROC)

### Métricas de Negocio:

- **Tasa de error operativo**  $[(FP + FN) / (VP + VN + FP + FN)] * 100$
- Costo de error  
(FP + FN) \* Cu : Tomando Cu como costo promedio de tomates y manzanas.

Pero el costo de manzanas y tomates reales tiene mucha diferencia entre si, entonces se debe hacer una diferencia entre estos errores.

Definición

F<sub>Pt</sub> : Número de tomates mal clasificados

F<sub>Nm</sub>: Número de manzanas mal clasificadas.

C<sub>t</sub> y C<sub>m</sub>

**Costo total operativo**

$$Et = (F_{Pt} * C_t) + (F_{Nm} * C_m)$$

**Costo medio**

$$Et / (VP + VN + FP + FN)$$

“Al optimizar el modelo para reducir falsos negativos en la clase de mayor costo (manzanas), el *recall* va a mejorar, además disminuye el gasto operativo generando un mejor retorno a la Inversión ROI”

## 5. Referencias y resultados previos

Samuel Cortinhas. (s.f.). Apples or tomatoes – Image Classification [Dataset]. Kaggle.  
<https://www.kaggle.com/datasets/samuelcortinhas/apples-or-tomatoes-image-classification>

Prthmgoyl. (s.f.). EfficientNet + ResNet + VGG: Tomato vs Apple [Notebook]. Kaggle.  
<https://www.kaggle.com/code/prthmgoyl/efficientnet-resnet-vgg-tomato-vs-apple/notebook>

Ahmed essam. (s.f.). *Apple-Tomatoes Classification* [Notebook]. Kaggle.  
<https://www.kaggle.com/code/ahmedessammukhtar/apple-tomatoes-classification/notebook>